

RuFLEX: гибридная платформа глубокого нечеткого интеллекта для геоданных с логической прослеживаемостью правил и контрфактуальной объяснимостью

Лебедев М.Д. [1], Трофимов Ю.В. [2, 4], Лебедев А.Д. [2], Аверкин А.Н. [2], Ильин А.С. [3], Алексеев А.К. [2]

1 НИТУ МИСИС, Москва, Россия

2 Государственный университет «Дубна», Дубна, Россия

3 Университет Иннополис, Иннополис, Россия

4 Объединенный институт ядерных исследований, Дубна, Россия

ORCID: М.Д. Лебедев — 0009-0005-1459-9119; Ю.В. Трофимов — 0009-0005-6943-7432; А.Д. Лебедев — 0009-0001-1046-5982; А.Н. Аверкин — 0000-0003-1571-3583; А.С. Ильин — 0009-0007-9599-4958; А.К. Алексеев — 0009-0005-6905-1900

Аннотация. В работе представлена платформа RuFLEX для гибридного глубокого нечеткого обучения, ориентированная на обработку геоданных в задачах, где высокая прогностическая точность должна сочетаться с интерпретируемостью, экспертной верифицируемостью и прозрачностью логики вывода. В отличие от традиционных black-box-подходов, предложенная архитектура объединяет дифференцируемые нечеткие слои, глубокие нечеткие свёртки и rule-based механизмы принятия решений в едином end-to-end контуре, реализованном в экосистеме PyTorch. Модельный контур поддерживает совместное обучение параметров функций принадлежности, базы правил и глубоких представлений признаков при сохранении семантически интерпретируемого вывода на уровне факторов и правил. Платформа включает программное ядро в виде Python SDK, веб-интерфейс визуального проектирования моделей и Explainability Dashboard, обеспечивающий анализ функций принадлежности, структуры правил и вклада факторов в итоговое решение. Перспективным направлением развития является расширение контура объяснимости в сторону логической прослеживаемости правил и контрфактуального анализа. Предлагаемый подход предназначен для прикладной валидации в задачах геоаналитики,

пространственной классификации, прогнозирования и интеллектуальной поддержки принятия решений.

Ключевые слова: глубокое нечеткое обучение; гибридные нейро-нечеткие модели; глубокое нечеткое формирование признаков; геоаналитика; пространственная классификация; объяснимое машинное обучение.

I. Введение

Задачи геоаналитики, пространственной классификации, прогнозирования и интеллектуальной поддержки принятия решений предъявляют к моделям двойное требование. С одной стороны, необходимо добиваться высокой точности прогноза. С другой стороны, требуется сохранять прозрачность логики вывода, возможность экспертной проверки базы правил и содержательное объяснение того, какие факторы определили ответ модели на конкретном объекте. По этой причине непрозрачные архитектуры не решают задачу полностью даже тогда, когда обеспечивают приемлемый уровень качества. Для прикладных сценариев важны не только итоговые значения метрик, но и интерпретируемая структура самого вычислительного процесса [1, 5, 10, 11].

Нечеткие и нейро-нечеткие подходы сохраняют связь между числовыми признаками, лингвистическими термами и правилами, поэтому они естественным образом подходят для задач, в которых наряду с точностью требуется объяснимость [1, 8, 9]. Однако современная постановка вопроса выходит за пределы одной модели. Исследователю необходима программная среда, позволяющая задавать переменные и термы, строить и сравнивать разные архитектурные режимы, обучать параметры функций принадлежности и правил, сохранять воспроизводимость вычислительного опыта и получать интерпретируемые аналитические материалы. Именно эта логика и определяет платформенный характер RuFLEX.

В настоящей работе RuFLEX рассматривается как гибридная платформа глубокого нечеткого обучения, а не как частный вариант одной нейро-нечеткой сети. Цель статьи состоит в описании архитектуры платформы, формализации ее модельного контура и прикладной демонстрации работы на геоориентированных задачах регрессии и классификации. Основные результаты работы состоят в следующем. Предлагается модульная

архитектура платформы, объединяющая описание данных, нечеткие переменные, локальные правилые блоки, глубокий и плоский режимы, обучение и интерпретацию. Формализуется представление глубины как последовательного построения скрытых нечетких концептов. Приводится воспроизводимый сравнительный экспериментальный контур, позволяющий сопоставлять архитектурные абляции RuFLEX с сильными табличными моделями на нескольких геоориентированных задачах. Прикладная валидация в рамках данной статьи относится прежде всего к табличному геоаналитическому ядру платформы и к встроенным средствам интерпретации на уровне термов, правил, скрытых концептов и вкладов факторов, тогда как пространственный сверточный каркас, полный контур логической прослеживаемости правил и контрфактуальный анализ рассматриваются как архитектурно предусмотренные направления дальнейшего развития.

II. Архитектура и модульный состав платформы

RuFLEX реализована как самостоятельная программная платформа на базе PyTorch [2], в которой вычислительное ядро глубокого нечеткого обучения соединено с собственным контуром описания проекта, обучения, визуального проектирования и анализа результатов. Такое решение позволяет рассматривать платформу не как изолированную модель, а как целостную среду построения и исследования гибридных нечетких архитектур. Внутренний вычислительный модуль, восходящий к ранее разработанному глубоко-нечеткому программному контуру [7], отвечает за фазификацию, вычисление активаций правил, формирование скрытых концептов и получение итогового ответа. Платформенный контур отвечает за описание данных, конфигурирование моделей, журналирование, воспроизводимость, визуализацию, интерпретацию и экспорт материалов.

В вычислительном отношении платформа опирается на две согласованные конфигурации модельного контура. Первая конфигурация является плоской и включает один локальный признаковый блок и решающий правилый слой. Вторая конфигурация является иерархической и состоит из последовательности стадий, каждая из которых содержит несколько прозрачных локальных блоков, после чего завершается общим решающим слоем. Благодаря этому глубина в RuFLEX задается не декларативно, а через

явную композицию стадий, блоков, скрытых концептов и финального решающего контура.

Архитектура RuFLEX последовательно разворачивается через несколько взаимосвязанных модулей. Первый модуль задает описание данных и переменных. На этом уровне фиксируются входные и выходные переменные, диапазоны их значений, роли признаков, принадлежность переменной к входному, скрытому или выходному уровню, а также режимы нормализации. Благодаря этому модель изначально строится не над абстрактным набором безымянных координат, а над семантически определенным пространством признаков.

Второй модуль образуют термы и функции принадлежности. Для каждой переменной платформа поддерживает гауссовы, колоколообразные, треугольные и трапециевидные функции принадлежности. В дифференцируемых режимах основная роль принадлежит гладким семействам, поскольку именно они допускают устойчивое совместное обучение с параметрами правил и внутренних представлений. Этот модуль переводит исходное числовое пространство в нечеткое описание, пригодное для дальнейшего построения правилых структур.

Третий модуль составляет правилый контур. В нем задаются антецеденты, способы агрегации, веса правил, параметры заключений и локальные базы правил. Важной особенностью платформы является использование ограниченных правилых блоков. Вместо одной глобальной базы правил для всех переменных сразу вводятся локальные блоки, каждый из которых работает с ограниченным набором входов и ограниченным числом правил. Такая организация одновременно решает две задачи. Она сдерживает рост сложности и создает структурную основу для перехода к глубокой композиции нечетких представлений.

Четвертый модуль является центральным в архитектуре платформы. Он реализует глубокое нечеткое формирование признаков. Скрытые уровни в RuFLEX трактуются как механизм построения новых нечетких концептов, а не как непрозрачное внутреннее кодирование. Каждый скрытый уровень формируется из локальных правилых блоков, а каждый блок порождает один или несколько скрытых концептов, которые затем используются как вход для следующего уровня. В результате модель строит последовательность

интерпретируемых концептуальных представлений, постепенно переходя от исходных признаков к более выразительному пространству. Такая трактовка глубины согласуется с современным направлением глубокого нечеткого формирования признаков [6], но в RuFLEX она реализована как режим внутри единой платформы.

Практически важная особенность реализованной архитектуры состоит в том, что иерархический контур задается не только как строгая последовательная цепочка стадий. Решающий слой может получать либо только финальные скрытые концепты, либо объединенное представление из исходных признаков и последних или всех скрытых стадий. Для табличных геоданных именно такая схема поступления признаковой информации оказывается критичной, поскольку позволяет избежать информационной воронки, возникающей в слишком узком последовательном иерархическом контуре. Кроме того, локальные блоки могут строиться с перекрытием, а их размер варьируется между парами и тройками признаков, что дает возможность управлять локальным масштабом взаимодействий.

Пятый модуль соответствует плоскому интерпретируемому нейро-нечеткому режиму. Он необходим как базовая конфигурация, как сравнительный режим и как практический вариант для задач, где особенно важны компактность и прозрачность вывода. В этом случае фаззификация относительно быстро переходит к локальным правилам и решающему слою без развернутой иерархии скрытых концептов. По своей структуре такой режим соответствует компактной нейро-нечеткой модели по типу Сугено и функционально близок к классическому ANFIS [1], поскольку сочетает один слой нечеткого преобразования признаков с финальным правилowym решающим слоем. Наличие в одной платформе и глубокого, и плоского режимов имеет принципиальное значение. Оно позволяет сопоставлять архитектуры внутри единой вычислительной среды и выбирать конфигурацию, соответствующую структуре задачи.

Шестой модуль связан с обучением и регуляризацией. Платформа поддерживает начальную инициализацию, поэтапное предварительное обучение, последующее совместное дообучение, сохранение лучших состояний и воспроизводимые вычислительные опыты. Регуляризация направлена не только на повышение качества прогноза, но и на поддержание интерпретируемости. Она охватывает разреженность правил, контроль

перекрытия термов, покрытие пространства признаков и различимость скрытых концептов.

Седьмой модуль образует контур интерпретации. Он включает анализ функций принадлежности, активированных правил, нормированных весов, вкладов правил в скрытые концепты, вкладов скрытых концептов в итоговый ответ и вкладов исходных факторов в решение модели. На пользовательском уровне этот контур представлен Python SDK, веб-интерфейсом визуального проектирования и Explainability Dashboard. Реализованный интерпретационный контур уже поддерживает анализ цепочек правил, траекторий скрытых концептов и вклада факторов. Тем самым платформа дает содержательно интерпретируемый аналитический контур, но полная логическая прослеживаемость правил и отдельный контрфактуальный модуль в данной статье еще не выступают как самостоятельно завершенные экспериментально верифицированные подсистемы.

Наконец, в архитектуре платформы предусмотрен пространственный сверточный каркас глубокого нечеткого вывода. В текущем состоянии он согласован с общей модельной схемой и подготовлен как расширяемый модуль для дальнейшего развития пространственного направления. В рамках данного исследования этот контур рассматривается как архитектурно включенный, но еще не доведенный до полной прикладной зрелости модуль. В настоящей статье он не проходит отдельной количественной валидации и служит прежде всего указанием на направление следующего этапа платформенного развития.




Схема 1. Общая архитектура RuFLEX: вычислительное ядро, платформенный слой и исследовательские сервисы.




Схема 2. Модельный контур RuFLEX: плоский и глубокий режимы, скрытые концепты и пространственный каркас.




Схема 3. Контур интерпретации: от фаззификации объекта к правилам, концептам и аналитическим материалам.

III. Математическая структура модельного контура

Пусть входной объект описывается вектором признаков

$$x = (x_1, x_2, \dots, x_d)$$

Для каждой переменной задается отображение нормализации ϕ_i , после чего формируется исходное представление

$$z_i^{(0)} = \phi_i(x_i), \quad i = 1, 2, \dots, d$$

а весь входной слой записывается как

$$z^{(0)}(x) = (z_1^{(0)}, z_2^{(0)}, \dots, z_d^{(0)})$$

Для i -й переменной и j -го терма задается функция принадлежности

$$\mu_{ij}(z_i^{(0)}; \theta_{ij})$$

где θ_{ij} обозначает набор обучаемых параметров. Для гауссовой функции принадлежности используется выражение

$$\mu_{ij}(z_i^{(0)}) = \exp\left(-\frac{(z_i^{(0)} - c_{ij})^2}{2\sigma_{ij}^2}\right)$$

где c_{ij} является центром терма, а σ_{ij} задает его ширину. Для колоколообразной функции принадлежности используется выражение

$$\mu_{ij}(z_i^{(0)}) = \frac{1}{1 + \left| \frac{z_i^{(0)} - c_{ij}}{a_{ij}} \right|^{2b_{ij}}}$$

где a_{ij} и b_{ij} определяют масштаб и крутизну перехода.

Пусть на уровне l задано правило r , содержащее k_r антецедентов. Тогда его ненормированная активация определяется как

$$w_r^{(l)}(x) = \prod_{m=1}^{k_r} \mu_{i_m j_m}^{(l)}(z_{i_m}^{(l-1)}(x); \theta_{i_m j_m}^{(l)})$$

Для перехода к сопоставимым весам используется нормировка

$$\bar{w}_r^{(l)}(x) = \frac{w_r^{(l)}(x)}{\sum_s w_s^{(l)}(x) + \varepsilon}$$

где $\varepsilon > 0$ предотвращает вырождение знаменателя.

Если используется плоский интерпретируемый режим, то нормированные веса правил непосредственно участвуют в вычислении ответа. В глубоком режиме вводятся локальные блоки

$$B_q^{(l)}, \quad q = 1, 2, \dots, Q_l$$

каждый из которых формирует скрытый нечеткий концепт

$$h_q^{(l)}(x) = \sum_{r \in B_q^{(l)}} \bar{w}_r^{(l)}(x) \cdot g_r^{(l)}(z^{(l-1)}(x))$$

где $g_r^{(l)}$ обозначает заключение r -го правила. Если заключение задается линейной формой, то можно записать

$$g_r^{(l)}(z^{(l-1)}(x)) = \beta_{r0}^{(l)} + \sum_t \beta_{rt}^{(l)} z_t^{(l-1)}(x)$$

Тогда вектор

$$h^{(l)}(x) = (h_1^{(l)}(x), h_2^{(l)}(x), \dots, h_{Q_l}^{(l)}(x))$$

образует новое концептуальное пространство признаков на уровне l .

Глубина модели определяется числом последовательных уровней такого преобразования. Если модель содержит $L - 1$ скрытых уровней, то формируется цепочка

$$z^{(0)}(x) \rightarrow h^{(1)}(x) \rightarrow h^{(2)}(x) \rightarrow \dots \rightarrow h^{(L-1)}(x)$$

Каждый шаг этой цепочки переводит одно интерпретируемое нечеткое представление в другое. Именно в этом состоит смысл глубины в RuFLEX.

В реализованной архитектуре вектор, поступающий на решающий слой, обозначим $d(x)$. В зависимости от выбранной конфигурации он может совпадать с последним скрытым уровнем, объединять все скрытые уровни либо включать исходные нормализованные признаки вместе с финальными или всеми скрытыми концептами:

$$d(x) = h^{(L-1)}(x), \quad d(x) = [h^{(1)}(x), \dots, h^{(L-1)}(x)],$$

$$d(x) = [z^{(0)}(x), h^{(L-1)}(x)] \text{ или } d(x) = [z^{(0)}(x), h^{(1)}(x), \dots, h^{(L-1)}(x)].$$

Такая запись отражает важный архитектурный выбор между чисто последовательным глубоким контуром и прямой передачей признаковой информации к решающему слою.

Финальный решающий слой для задачи регрессии может быть записан как

$$\hat{y}(x) = \sum_{r \in B^{(L)}} \bar{w}_r^{(L)}(x) \cdot g_r^{(L)}(d(x))$$

Для бинарной классификации сначала вычисляется логит

$$s(x) = \sum_{r \in B^{(L)}} \bar{w}_r^{(L)}(x) \cdot g_r^{(L)}(d(x))$$

после чего вероятность положительного класса определяется выражением

$$\hat{p}(x) = \frac{1}{1 + \exp(-s(x))}$$

Совместное обучение параметров платформы задается функционалом

$$L = L_{\text{task}} + \lambda_1 L_{\text{sparsity}} + \lambda_2 L_{\text{overlap}} + \lambda_3 L_{\text{coverage}} + \lambda_4 L_{\text{concept}}$$

Для регрессии основное слагаемое может быть задано среднеквадратичной ошибкой

$$L_{\text{task}} = \frac{1}{N} \sum_{n=1}^N (y_n - \hat{y}(x_n))^2$$

а для бинарной классификации логистической потерей

$$L_{\text{task}} = -\frac{1}{N} \sum_{n=1}^N [y_n \log \hat{p}(x_n) + (1 - y_n) \log (1 - \hat{p}(x_n))]$$

Разреживающее слагаемое может быть записано в виде

$$L_{\text{sarsity}} = \sum_{l,r} |\alpha_r^{(l)}|$$

где $\alpha_r^{(l)}$ характеризует силу участия r -го правила в модели. Для контроля перекрытия термов используется выражение

$$L_{\text{overlap}} = \sum_{i,j < k} \int \mu_{ij}(t) \mu_{ik}(t) dt$$

а для поддержания различимости скрытых концептов

$$L_{\text{concept}} = \sum_l \sum_{q \neq p} \langle h_q^{(l)}, h_p^{(l)} \rangle^2$$

Тем самым оптимизация направлена одновременно на качество прогноза и на структурную интерпретируемость архитектуры.

Для пространственного каркаса вводится тензор признаков

$$X \in \mathbb{R}^{H \times W \times C}$$

Тогда локальный нечеткий сверточный отклик может быть записан как

$$u_m(u, v) = \sum_{(a, b, c) \in \Omega} \kappa_{mabc} \cdot \mu_{mabc}(X_{u+a, v+b, c})$$

где Ω задает локальное окно, κ_{mabc} являются обучаемыми весами, а μ_{mabc} описывают локальные функции принадлежности. В рамках данного исследования этот модуль рассматривается как согласованный с основной архитектурой расширяемый каркас. Приведенная запись фиксирует математическую совместимость пространственного контура с общей схемой RuFLEX, но не должна интерпретироваться как описание уже полноценно экспериментально проверенного модуля в пределах настоящей статьи.

Интерпретация решения строится через локальные вклады правил, концептов и факторов. Для правила финального слоя вклад может быть записан как

$$C_r(x) = \bar{w}_r^{(L)}(x) \cdot g_r^{(L)}(h^{(L-1)}(x))$$

Если правило относится к скрытому концепту q , то вклад концепта задается выражением

$$C_q^{(l)}(x) = \sum_{r \in B_q^{(l)}} C_r^{(l)}(x)$$

Вклад исходного признака восстанавливается через агрегирование по тем блокам и правилам, в которых данный признак участвовал. Благодаря этому интерпретация опирается на внутреннюю структуру модели, а не только на внешний постфактум-анализ.

IV. Экспериментальная постановка

Для прикладной проверки платформы используется расширенный воспроизводимый набор геоориентированных задач. В него входят California Housing Regression, California Value Binary Geo и Coverttype Binary Geo. Первая задача является регрессионной постановкой по переменной MedHouseVal на основе данных California Housing [4] при сохранении пространственных признаков Latitude и Longitude. Вторая задача строится на том же источнике данных в постановке бинарной классификации. Третья задача задает независимый стресс-тест текущего табличного контура на картографических признаках Forest CoverType.

Для California Housing Regression и California Value Binary Geo использовались подвыборки объема 4096 наблюдений, сформированные из исходного массива California Housing размером 20640 объектов. Для Coverttype Binary Geo использовалась сбалансированная подвыборка объема 6000 наблюдений, сформированная из бинаризованной части Forest CoverType, содержащей 495141 допустимый объект из исходного массива размером 581012 строк. Такой выбор соответствует постановке контролируемого сравнительного эксперимента с фиксированным бюджетом данных и вычислений, в котором все внутренние абляции RuFLEX и внешние

сравнительные модели сопоставляются в одинаковых условиях. Во всех вычислительных опытах данные делились на обучающую, проверочную и тестовую части с долями 0.6, 0.2 и 0.2 соответственно. Для повышения надежности выводов применялись повторные запуски с seed 11, 23 и 47 с последующим агрегированием результатов в виде $\text{mean} \pm \text{std}$. Тем самым экспериментальная часть данной статьи валидирует прежде всего табличный модельный контур RuFLEX и сопровождающий его интерпретационный анализ, но не претендует на отдельную завершённую проверку пространственного сверточного модуля и полного контура логической прослеживаемости правил.

Внутри платформы сравнивались плоская базовая конфигурация, плоская интерпретируемая конфигурация, конфигурация с одним скрытым уровнем, строго последовательная глубокая конфигурация без прямого доступа решающего слоя к исходным признакам, конфигурация с объединением исходных признаков и финальной скрытой стадии, а также контекстно-обогащённая конфигурация с перекрывающимися трехпризнаковыми блоками и доступом ко всем скрытым стадиям. Тем самым экспериментальный контур позволяет отдельно анализировать влияние глубины, схемы поступления признаковой информации и локального масштаба взаимодействий. С точки зрения нечетких систем первые две конфигурации выполняют роль одноуровневых ANFIS-подобных сравнительных режимов: они используют один нечеткий блок и финальный решающий слой по типу Сугено, обучаемые в том же дифференцируемом контуре. Для сопоставления с внешними табличными подходами использовались линейная или логистическая регрессия, градиентный бустинг, случайный лес и многослойный персептрон, реализованные в стандартном стеке табличного машинного обучения [3]. Поэтому работа содержит не только сравнение с сильными внешними сравнительными моделями, но и прямое сопоставление глубоких архитектур RuFLEX с компактными нейро-нечеткими режимами того же семейства.

Для регрессионных постановок анализировались RMSE, MAE и R^2 . Для классификационных постановок использовались точность классификации (accuracy), precision, recall и F1. Все вычислительные опыты выполнялись в воспроизводимом исследовательском контуре платформы с автоматическим сохранением метрик, таблиц, графиков и аналитических материалов.

Поэтому полученные выводы следует интерпретировать как результаты контролируемого сравнительного исследования архитектурных режимов при фиксированном бюджете данных и вычислений, а не как окончательную оценку предельного качества моделей на полных датасетах.

V. Результаты и интерпретация

Основной количественный результат на регрессионной задаче California Housing Regression состоит в том, что наилучшие внутренние показатели RuFLEX задаются не строго последовательным глубоким режимом, а конфигурациями, в которых исходные признаки и промежуточные скрытые представления не теряются на пути к решающему слою. В многосидовом протоколе лучший средний результат внутри семейства RuFLEX сохраняет конфигурация с одним скрытым уровнем: $RMSE = 0.677 \pm 0.062$, $MAE = 0.492 \pm 0.036$ и $R^2 = 0.625 \pm 0.072$. При этом строго последовательная глубокая конфигурация без прямой передачи исходных признаков дает заметно более слабые значения: $RMSE = 0.797 \pm 0.040$, $MAE = 0.597 \pm 0.014$ и $R^2 = 0.482 \pm 0.058$. Две расширенные глубокие конфигурации оказываются существенно лучше последовательного иерархического контура и практически выходят на уровень лучшей компактной конфигурации: для режима с объединением исходных признаков и финальной скрытой стадии получаем $RMSE = 0.686 \pm 0.058$, $MAE = 0.501 \pm 0.034$ и $R^2 = 0.615 \pm 0.069$, а для контекстного режима с трехпризнаковыми перекрывающимися блоками $RMSE = 0.682 \pm 0.046$, $MAE = 0.497 \pm 0.019$ и $R^2 = 0.620 \pm 0.056$.

Эти результаты имеют важный архитектурный смысл. Они показывают, что на табличной георегрессии критичным оказывается не столько абстрактное увеличение глубины, сколько способ передачи информации к решающему слою. Строго последовательный контур теряет часть полезного сигнала, тогда как прямая передача исходных признаков и перекрывающиеся локальные блоки резко сокращают разрыв между глубоким и компактным режимами. Относительно последовательной глубокой конфигурации новый контекстный режим снижает RMSE примерно на 14.5% и повышает R^2 примерно на 0.138. В этом смысле глубина в RuFLEX оказывается полезной тогда, когда она сопровождается адекватной схемой поступления признаковой информации, а не просто увеличением числа скрытых стадий.

Сравнение с внешними табличными моделями также принципиально важно. На той же регрессионной задаче сильнейшей внешней сравнительной моделью оказывается градиентный бустинг: $RMSE = 0.505 \pm 0.015$, $MAE = 0.349 \pm 0.010$ и $R^2 = 0.793 \pm 0.013$. Случайный лес и многослойный персептрон также превосходят все варианты RuFLEX по чистым предсказательным метрикам на данной выборке. Следовательно, работа направлена не на демонстрацию численного превосходства глубокого нечеткого контура над всеми табличными моделями, а на построение платформенно-системной среды, объединяющей гибридное нечеткое моделирование, интерпретируемость, архитектурную абстракцию, контур воспроизводимых сравнительных экспериментов, Python SDK, веб-интерфейс и Explainability Dashboard.

Классификационная задача California Value Binary Geo выполняет поддерживающую, но очень показательную функцию. Здесь наиболее сильный внутренний результат семейства RuFLEX дают глубокие конфигурации с прямой передачей признаков к решающему слою. Строго последовательная глубокая конфигурация показывает $accuracy = 0.746 \pm 0.008$ и $F1 = 0.745 \pm 0.012$, тогда как режим с объединением исходных признаков и финальной скрытой стадии дает $accuracy = 0.824 \pm 0.010$ и $F1 = 0.827 \pm 0.012$, а контекстный режим с трехпризнаковыми перекрывающимися блоками дает лучший средний $accuracy$, равный 0.825 ± 0.012 , при $F1 = 0.826 \pm 0.015$. Конфигурация с одним скрытым уровнем также остается сильной, но уже немного уступает по средним значениям $accuracy$ и $F1$: $accuracy = 0.820 \pm 0.011$ и $F1 = 0.823 \pm 0.012$. Следовательно, для данной задачи основной выигрыш дает не отказ от глубины, а правильная передача исходных признаков и скрытых концептов к решающему слою. При этом лучший внешний результат, градиентный бустинг, по-прежнему выше: $accuracy = 0.892 \pm 0.006$ и $F1 = 0.895 \pm 0.007$.

Coverttype Binary Geo теперь играет уже не роль негативного контроля, а роль независимого стресс-теста, на котором хорошо видно влияние архитектурного решения на устойчивость обучения. Строго последовательная глубокая конфигурация на этой задаче по-прежнему ведет себя нестабильно и фактически деградирует до почти случайного решения: $accuracy = 0.497 \pm 0.015$ и $F1 = 0.225 \pm 0.390$. Напротив, конфигурация с одним скрытым уровнем и режим с объединением исходных признаков и финальной скрытой стадии практически совпадают по среднему качеству и выходят на уровень $accuracy$

≈ 0.772 и $F1 \approx 0.772$, а контекстный трехпризнаковый режим дает ассигасу = 0.770 ± 0.011 и $F1 = 0.771 \pm 0.016$. Это означает, что новая схема поступления признаковой информации почти полностью снимает архитектурный провал последовательного глубокого контура и делает глубокий нечеткий режим содержательно работоспособным даже на более сложной картографической задаче. При этом случайный лес остается сильнее: ассигасу = 0.804 ± 0.001 и $F1 = 0.808 \pm 0.001$. Следовательно, Coverture по-прежнему выявляет предел текущего табличного режима по отношению к сильным древесным ансамблям и другим внешним сравнительным моделям, но уже не свидетельствует о его внутренней деградации.

Содержательно такая картина хорошо согласуется со структурой данных. На компактной табличной георегрессии полезность глубины проявляется только тогда, когда решающий слой не вынужден опираться исключительно на последний скрытый уровень. На классификационных задачах наибольший выигрыш дают конфигурации с прямым доступом к исходным признакам и с более широкими локальными взаимодействиями. Тем самым ценность RuFLEX состоит не в навязывании одной универсальной глубокой схемы, а в возможности устанавливать, какой способ компоновки локальных блоков и поступления признаковой информации соответствует конкретной задаче.

Дополнительная проверка на увеличенных выборках, вынесенная в расширенные материалы, усиливает именно этот вывод. На полном California Housing Regression лучший режим с прямой передачей признаков дает $RMSE = 0.705$ и $R^2 = 0.621$ против $RMSE = 0.799$ и $R^2 = 0.513$ у последовательной глубокой конфигурации. На увеличенной California Value Binary Geo контекстный режим с перекрывающимися блоками дает ассигасу = 0.847 и $F1 = 0.846$ против ассигасу = 0.764 и $F1 = 0.746$ у последовательного глубокого контура. Следовательно, рост объема данных действительно помогает глубокому нечеткому контуру, но лишь в том случае, если архитектура не теряет исходный признаковый сигнал и промежуточные концепты на пути к решающему слою.

Содержательная ценность платформы определяется не только итоговыми метриками. Для лучших конфигураций автоматически формируются графики функций принадлежности, история обучения, представления наиболее активных правил, скрытых концептов, цепочек правил и аналитические панели для отдельных объектов. Поэтому количественные

результаты сопровождаются материалами, позволяющими проследить, каким образом ответ модели связан с активированными правилами, нечеткими термами, промежуточными концептами и вкладом факторов. Для рецензируемой публикации это существенно усиливает аргументацию, поскольку качество прогноза подтверждается внутренне интерпретируемой структурой вывода.

Таблица. California Housing Regression: агрегированные результаты mean $\pm$ std

Модель	Класс	RMSE	MAE	R ²
Linear Regression	Внешний baseline	0.699 $\pm$ 0.048	0.516 $\pm$ 0.028	0.601 $\pm$ 0.057
Gradient Boosting	Внешний baseline	0.505 $\pm$ 0.015	0.349 $\pm$ 0.010	0.793 $\pm$ 0.013
Random Forest	Внешний baseline	0.571 $\pm$ 0.017	0.393 $\pm$ 0.010	0.734 $\pm$ 0.018
MLP	Внешний baseline	0.582 $\pm$ 0.028	0.415 $\pm$ 0.017	0.724 $\pm$ 0.026
Плоская базовая конфигурация	RuFLEX	0.869 $\pm$ 0.023	0.655 $\pm$ 0.013	0.386 $\pm$ 0.038
Плоская интерпретируемая конфигурация	RuFLEX	1.086 $\pm$ 0.018	0.860 $\pm$ 0.010	0.041 $\pm$ 0.039
<i>Глубокая конфигурация с одним скрытым уровнем</i>	RuFLEX	0.677 $\pm$ 0.062	0.492 $\pm$ 0.036	0.625 $\pm$ 0.072
Строго последовательная глубокая конфигурация	RuFLEX	0.797 $\pm$ 0.040	0.597 $\pm$ 0.014	0.482 $\pm$ 0.058
Глубокая конфигурация с объединением исходных признаков и финальной стадии	RuFLEX	0.686 $\pm$ 0.058	0.501 $\pm$ 0.034	0.615 $\pm$ 0.069
Контекстная глубокая конфигурация	RuFLEX	0.682 $\pm$ 0.046	0.497 $\pm$ 0.019	0.620 $\pm$ 0.056

Жирным выделен лучший общий результат. Курсивом отмечен лучший результат внутри семейства RuFLEX.

Таблица. California Value Binary Geo: агрегированные результаты mean $\pm$ std

Модель	Класс	Accuracy	F1	Precision	Recall
Logistic Regression	Внешний baseline	0.834 $\pm$ 0.009	0.838 $\pm$ 0.009	0.834 $\pm$ 0.015	0.842 $\pm$ 0.004
Gradient Boosting	Внешний baseline	0.892 $\pm$ 0.006	0.895 $\pm$ 0.007	0.886 $\pm$ 0.007	0.903 $\pm$ 0.007
Random Forest	Внешний baseline	0.868 $\pm$ 0.001	0.870 $\pm$ 0.002	0.869 $\pm$ 0.005	0.872 $\pm$ 0.009
MLP	Внешний baseline	0.871 $\pm$ 0.005	0.874 $\pm$ 0.004	0.869 $\pm$ 0.011	0.880 $\pm$ 0.004

Плоская базовая конфигурация	RuFLEX	0.737 ± 0.011	0.733 ± 0.009	0.758 ± 0.026	0.710 ± 0.008
Плоская интерпретируемая конфигурация	RuFLEX	0.650 ± 0.117	0.482 ± 0.341	0.514 ± 0.368	0.465 ± 0.338
Глубокая конфигурация с одним скрытым уровнем	RuFLEX	0.820 ± 0.011	0.823 ± 0.012	0.823 ± 0.014	0.823 ± 0.015
Строго последовательная глубокая конфигурация	RuFLEX	0.746 ± 0.008	0.745 ± 0.012	0.761 ± 0.013	0.729 ± 0.017
<i>Глубокая конфигурация с объединением исходных признаков и финальной стадии</i>	RuFLEX	0.824 ± 0.010	0.827 ± 0.012	0.827 ± 0.007	0.827 ± 0.018
Контекстная глубокая конфигурация	RuFLEX	0.825 ± 0.012	0.826 ± 0.015	0.833 ± 0.008	0.820 ± 0.023

Жирным выделен лучший общий результат. Курсивом отмечен лучший результат внутри семейства RuFLEX.

Таблица. Coverttype Binary Geo: агрегированные результаты mean ± std

Модель	Класс	Accuracy	F1	Precision	Recall
Logistic Regression	Внешний baseline	0.772 ± 0.009	0.772 ± 0.013	0.785 ± 0.016	0.760 ± 0.020
Gradient Boosting	Внешний baseline	0.783 ± 0.003	0.786 ± 0.005	0.789 ± 0.008	0.784 ± 0.011
Random Forest	Внешний baseline	0.804 ± 0.001	0.808 ± 0.001	0.807 ± 0.009	0.809 ± 0.010
MLP	Внешний baseline	0.778 ± 0.007	0.782 ± 0.009	0.783 ± 0.010	0.782 ± 0.027
Плоская базовая конфигурация	RuFLEX	0.490 ± 0.007	0.222 ± 0.314	0.166 ± 0.235	0.333 ± 0.471
Плоская интерпретируемая конфигурация	RuFLEX	0.490 ± 0.007	0.222 ± 0.314	0.166 ± 0.235	0.333 ± 0.471
<i>Глубокая конфигурация с одним скрытым уровнем</i>	RuFLEX	0.772 ± 0.011	0.772 ± 0.015	0.786 ± 0.022	0.759 ± 0.025
Строго последователь	RuFLEX	0.497 ± 0.015	0.225 ± 0.390	0.170 ± 0.294	0.333 ± 0.577

ная глубокая конфигурация					
Глубокая конфигурация с объединением исходных признаков и финальной стадии	RuFLEX	0.772 ± 0.011	0.772 ± 0.015	0.786 ± 0.024	0.759 ± 0.025
Контекстная глубокая конфигурация	RuFLEX	0.770 ± 0.011	0.771 ± 0.016	0.782 ± 0.021	0.760 ± 0.029

Жирным выделен лучший общий результат. Курсивом отмечен лучший результат внутри семейства RuFLEX.

VI. Заключение

В работе представлена платформа RuFLEX для гибридного глубокого нечеткого обучения, ориентированная на обработку геоданных и объединяющая дифференцируемые нечеткие слои, модуль глубокого нечеткого формирования признаков, плоский интерпретируемый нейронечеткий режим, правилый контур, средства совместного обучения и встроенный модуль интерпретации. Основной методический итог статьи состоит в том, что глубина в RuFLEX формализуется как последовательное построение скрытых нечетких концептов из локальных правилых блоков, а не как простое наращивание числа непрозрачных внутренних слоев. Тем самым платформа задает единую среду, в которой можно сопоставлять архитектурные режимы, обучающие стратегии и интерпретационные материалы в рамках одного воспроизводимого контура. При этом экспериментально подтвержденным ядром статьи выступают табличный геоаналитический контур и встроенные средства интерпретации на уровне правил, концептов и факторов.

Экспериментальная проверка показывает, что для реализованных табличных глубоких режимов RuFLEX решающим оказывается не абстрактное увеличение глубины, а способ поступления признаковой информации к решающему слою. Конфигурации с прямым доступом к исходным признакам и скрытым концептам резко улучшают результаты относительно строгой последовательной глубокой схемы, особенно на классификации и на стресс-тесте Coverttype. Одновременно сравнение с внешними табличными моделями показывает, что на компактных выборках

сильные классические методы по-прежнему могут превосходить гибридный нечеткий контур по чистой метрике. Дополнительная проверка на увеличенных выборках в расширенных материалах уточняет этот вывод: при росте объема данных такие конфигурации усиливаются заметнее, чем последовательный глубокий контур. Следовательно, наиболее точное позиционирование RuFLEX состоит не в претензии на универсальное численное превосходство, а в построении платформы сравнения, отбора и объяснимого анализа архитектурных режимов при сохранении прозрачности вывода и воспроизводимости вычислительного опыта.

Практическая ценность RuFLEX заключается в том, что платформа уже позволяет выбирать между компактными, иерархическими и контекстно-обогащенными режимами, анализировать решение на уровне термов, правил, скрытых концептов и факторов и сопровождать количественные результаты внутренне интерпретируемыми материалами. Пространственный сверточный контур, полный режим логической прослеживаемости правил и контрфактуальная интерпретация в настоящей статье выступают как архитектурно согласованные и частично подготовленные направления следующего этапа, а не как полностью завершенные и отдельно подтвержденные прикладные модули. Дальнейшее развитие связано с их усилением, а также с расширением экспериментальной проверки за пределы фиксированных сравнительных подвыборок, включая большее число seed, более объемные геоданные и дополнительные архитектурные режимы пространственного типа.

Список литературы

1. Jang J.-S. R. ANFIS: Adaptive-Network-Based Fuzzy Inference System // IEEE Transactions on Systems, Man, and Cybernetics. 1993. Vol. 23, No. 3. P. 665-685.
2. Paszke A., Gross S., Massa F. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. 2019. Vol. 32.
3. Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. 2011. Vol. 12. P. 2825-2830.
4. Pace R. K., Barry R. Sparse Spatial Autoregressions // Statistics & Probability Letters. 1997. Vol. 33, No. 3. P. 291-297. DOI: 10.1016/S0167-7152(96)00140-X.
5. Rudin C. Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead // Nature Machine Intelligence. 2019. Vol. 1. P.

206-215. DOI: 10.1038/s42256-019-0048-x. 6. Ma X., Chen L., Deng Z. et al. Deep Image Feature Learning With Fuzzy Rules // IEEE Transactions on Emerging Topics in Computational Intelligence. 2024. Vol. 8. P. 724-737. DOI: 10.1109/TETCI.2023.3259447. 7. Lebedeffson. deep-neuro-fuzzy [Электронный ресурс]. URL: <https://github.com/lebedeffson/deep-neuro-fuzzy> (дата обращения: 13.04.2026). 8. Zadeh L. A. Fuzzy Sets // Information and Control. 1965. Vol. 8, No. 3. P. 338-353. DOI: 10.1016/S0019-9958(65)90241-X. 9. Wang L.-X., Mendel J. M. Generating Fuzzy Rules by Learning from Examples // IEEE Transactions on Systems, Man, and Cybernetics. 1992. Vol. 22, No. 6. P. 1414-1427. DOI: 10.1109/21.199466. 10. Ribeiro M. T., Singh S., Guestrin C. "Why Should I Trust You?": Explaining the Predictions of Any Classifier // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016. P. 1135-1144. DOI: 10.1145/2939672.2939778. 11. Doshi-Velez F., Kim B. Towards a Rigorous Science of Interpretable Machine Learning // arXiv preprint arXiv:1702.08608. 2017.