

RuFLEX: гибридная платформа глубокого нечеткого обучения для геоданных с интерпретируемым анализом правил, факторов и скрытых концептов

И. О. Автор¹, И. О. Автор²

Организация, город, страна

E-mail: author1@example.com, author2@example.com

ORCID: 0000-0000-0000-0000, 0000-0000-0000-0000

Аннотация

В работе представлена платформа RuFLEX для гибридного глубокого нечеткого обучения, ориентированная на задачи геоаналитики, пространственно обусловленной классификации, прогнозирования и интеллектуальной поддержки принятия решений. В отличие от black-box-подходов, платформа объединяет интерпретируемые rule-based механизмы, дифференцируемые нечеткие слои и архитектуры deep fuzzy feature learning в едином контуре, реализованном на Python и PyTorch. Экспериментальная валидация проведена на двух geo-oriented табличных задачах: California Housing Regression и California Value Binary Geo. На regression-задаче лучший результат показала конфигурация Deep Research, а на binary classification лучшей оказалась конфигурация Flat Interpretable.

Ключевые слова: глубокое нечеткое обучение; hybrid neuro-fuzzy models; deep fuzzy feature learning; explainability; геоаналитика; интерпретируемое машинное обучение

1. Введение

RuFLEX позиционируется как платформенный слой для гибридного глубокого нечеткого обучения, а не как одна фиксированная модель. Платформа развивает собственные SDK/UI/explainability-компоненты поверх vendored deep fuzzy backend `ruanfis`, происходящего из репозитория `deep-neuro-fuzzy`. Такое разделение позволяет сохранять преемственность deep fuzzy ядра и одновременно развивать собственный исследовательский и прикладной контур.

Ключевая идея работы состоит в объединении плоских интерпретируемых neuro-fuzzy baseline-конфигураций и режима deep fuzzy feature learning в единой воспроизводимой платформе, которая поддерживает не только обучение и инференс, но и анализ функций принадлежности, правил, скрытых концептов и вклада факторов.

2. Архитектура платформы и модельные режимы

Текущая архитектура RuFLEX включает ядро платформы, модельный слой, слой обучения, explainability layer и инструментальный слой. В первой версии реализованы два базовых режима: flat neuro-fuzzy baseline и deep fuzzy feature learning. Первый режим удобен для компактного и интерпретируемого предсказания, второй использует скрытые слои как механизм формирования новых нечетких концептов.

- Python SDK и toolbox-style API
- visual workbench на базе Streamlit
- stage-wise pretraining, refinement и fine-tuning
- Explainability Dashboard с анализом membership functions, rules и hidden concepts
- reproducible article benchmark pipeline

3. Экспериментальная постановка

Для валидации использованы две geo-oriented табличные задачи. Первая задача, California Housing Regression, основана на ``sklearn.fetch_california_housing`` и использует пространственные признаки ``Latitude`` и ``Longitude``. Вторая задача, California Value Binary Geo, построена на том же наборе данных, но в постановке сбалансированной бинарной классификации по признаку ``HighValue``.

Во всех экспериментах сравнивались конфигурации Flat Baseline, Flat Interpretable, Deep Article Demo и Deep Research. Все результаты были получены в воспроизводимом article suite-контуре.

4. Результаты

На задаче California Housing Regression лучшей конфигурацией оказалась Deep Research (``test_rmse = 0.795757``, ``test_r2 = 0.507159``). На задаче California Value Binary Geo лучшей конфигурацией оказалась Flat Interpretable (``test_accuracy = 0.746341``, ``test_f1 = 0.739348``). Тем самым разные режимы

RuFLEX оказываются предпочтительными на разных типах задач, что поддерживает именно платформенное позиционирование системы.

Таблица 1. Сравнение конфигураций на regression-задаче

Конфигурация	Test RMSE	Test MAE	Test R2
Flat Baseline	0.890950	0.678868	0.382192
Flat Interpretable	1.115952	0.880786	0.030747
Deep Article Demo	0.816314	0.610628	0.481367
Deep Research	0.795757	0.593770	0.507159

Таблица 2. Сравнение конфигураций на classification-задаче

Конфигурация	Test Accuracy	Test Precision	Test F1
Flat Baseline	0.742683	0.739899	0.735257
Flat Interpretable	0.746341	0.743073	0.739348
Deep Article Demo	0.739024	0.724221	0.738386
Deep Research	0.743902	0.741772	0.736181

5. Иллюстративные материалы explainability




Рис. 1. Сравнение flat и deep fuzzy конфигураций на задаче California Housing Regression.



Рис. 2. Explainability board для лучшей regression-конфигурации.




Рис. 3. Сравнение конфигураций RuFLEX на задаче California Value Binary Geo.




Рис. 4. Explainability board для лучшей classification-конфигурации.




Рис. 5. Пример функций принадлежности для интерпретируемой фаззификации входного признака.

6. Заключение

Разработана платформа RuFLEX для гибридного глубокого нечеткого обучения, объединяющая интерпретируемые rule-based механизмы, дифференцируемые нечеткие слои, deep fuzzy feature learning, SDK, visual workbench и explainability tooling в едином reproducible контуре. Показано, что платформа работает как на regression-, так и на classification-сценариях, а выбор лучшей конфигурации зависит от структуры задачи.

Перспективы дальнейшего развития включают mature spatial/deep fuzzy module, более развитую logical traceability engine, counterfactual explainability и перенос вычислительно тяжелых частей в C++.

Благодарность

При необходимости здесь указывается благодарность научному руководителю, коллегам или консультантам.

Финансирование

При наличии финансирования здесь указывается формулировка на русском языке.

Список литературы

1. Jang J.-S. R. ANFIS: Adaptive-Network-Based Fuzzy Inference System // IEEE Transactions on Systems, Man, and Cybernetics. 1993. Vol. 23, No. 3. P. 665-685.
2. Paszke A., Gross S., Massa F. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. 2019. Vol. 32.
3. Pedregosa F., Varoquaux G., Gramfort A. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. 2011. Vol. 12. P. 2825-2830.
4. Pace R. K., Barry R. Sparse Spatial Autoregressions // Statistics & Probability Letters. 1997. Vol. 33, No. 3. P. 291-297. DOI: 10.1016/S0167-7152(96)00140-X.
5. Rudin C. Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead // Nature Machine Intelligence. 2019. Vol. 1. P. 206-215. DOI: 10.1038/s42256-019-0048-x.
6. Ma X., Chen L., Deng Z. et al. Deep Image Feature Learning With Fuzzy Rules // IEEE Transactions on Emerging Topics in Computational Intelligence. 2024. Vol. 8. P. 724-737. DOI: 10.1109/TETCI.2023.3259447.

7. Lebedeffson. deep-neuro-fuzzy [Электронный ресурс]. URL: <https://github.com/lebedeffson/deep-neuro-fuzzy> (дата обращения: 13.04.2026).